

Abandono de clientes de telecomunicaciones: formulación del problema y análisis exploratorio

1st Sofia Valentina Ku Paredes

Universidad de Ingeniería y Tecnología (UTEC)

Lima, Perú

sofia.ku@utec.edu.pe

2nd Given Name Surname

Universidad de Ingeniería y Tecnología (UTEC)

Lima, Perú

email address or ORCID

3rd Given Name Surname

Universidad de Ingeniería y Tecnología (UTEC)

Lima, Perú

email address or ORCID

4th Given Name Surname

Universidad de Ingeniería y Tecnología (UTEC)

Lima, Perú

email address or ORCID

5th Given Name Surname

dept. name of organization (of Aff.)

name of organization (of Aff.)

City, Country

email address or ORCID

Resumen—El abandono de clientes constituye un problema de interés para las empresas de telecomunicaciones porque reduce la continuidad de sus ingresos y motiva la búsqueda de estrategias de retención. Este proyecto plantea una tarea de clasificación binaria para identificar el abandono registrado a partir de características del cliente, sus servicios y su cuenta. Se utiliza Telco Customer Churn, un conjunto público de ejemplo de IBM distribuido en Kaggle, con 7043 observaciones y 21 columnas. La primera etapa comprende la descripción del problema y de las variables, la revisión de calidad y el análisis exploratorio de sus distribuciones y asociaciones. También se revisan posibles sesgos y riesgos de fuga de información que deberán considerarse antes de entrenar los modelos. Esta entrega se centra en el EDA y prepara la base para la siguiente etapa de modelado y evaluación.

Palabras clave—Abandono de clientes, telecomunicaciones, clasificación binaria, análisis exploratorio de datos.

I. INTRODUCCIÓN Y FORMULACIÓN DEL PROBLEMA

La retención de clientes es una de las principales prioridades estratégicas en las empresas de telecomunicaciones. En mercados altamente competitivos, la pérdida de clientes no solo reduce los ingresos mensuales, sino que además incrementa los costos asociados a la adquisición de nuevos usuarios y puede deteriorar la estabilidad del portafolio de clientes. En este contexto, comprender qué factores explican la salida de clientes resulta esencial para diseñar políticas de retención, mejorar la experiencia del usuario y optimizar los servicios ofrecidos.

El problema de *churn* se define como la decisión de un cliente de abandonar un servicio o cambiar de proveedor. En la práctica, este fenómeno resulta observable a través de datos históricos de comportamiento, uso del servicio, duración del contrato y variables de facturación. La capacidad de identificar tempranamente a clientes con alto riesgo de churn permite a la

empresa intervenir de forma proactiva antes de que el cliente abandone por completo.

Este proyecto se centra en el análisis del conjunto de datos Telco Customer Churn [1], una base ampliamente usada en el contexto de la predicción de retención. IBM lo presenta como información de ejemplo de una empresa ficticia [2].

A. Objetivo

El objetivo principal es comprender el problema de churn desde una perspectiva estadística y analítica, formular la tarea de Machine Learning y preparar la base para el modelado supervisado en etapas posteriores. Asimismo, se busca comprender el contexto del problema y su relevancia empresarial; caracterizar el dataset y sus variables relevantes; detectar patrones de churn en los datos; identificar riesgo de leakage, faltantes y anomalías; así como preparar una base metodológica sólida para la etapa de modelado predictivo.

B. Preguntas de investigación

1. ¿Qué características presentan diferencias en la proporción de abandono observado?
2. ¿Las diferencias por contrato se mantienen al comparar grupos de antigüedad similares?
3. ¿Cómo se relacionan el tipo de internet y los servicios adicionales con el abandono, y qué diferencias permanecen dentro de cada contrato?
4. ¿Qué problemas de calidad, representatividad y fuga de información deben considerarse antes del modelado?

C. Formulación del problema

El problema de churn puede representarse como una tarea de clasificación supervisada binaria. Dado un conjunto de

observaciones $\mathbf{x}_i$ que describen a cada cliente, se busca aprender una función $f(\mathbf{x}_i)$ tal que:

$$\hat{y}_i = f(\mathbf{x}_i) \in \{\text{No}, \text{Yes}\} \quad (1)$$

donde $\hat{y}_i$ representa la predicción de si el cliente abandona el servicio (Yes) o no (No).

El conjunto de variables de entrada incluye características demográficas, condiciones del contrato, servicios contratados, pagos y métricas de uso. La variable objetivo, Churn, es binaria y resume la decisión final del cliente respecto a su continuidad con el proveedor.

Desde la perspectiva del aprendizaje automático, el reto principal no solo reside en la predicción, sino en la correcta identificación de clientes en riesgo. Esto exige un análisis robusto de las relaciones entre variables, así como una evaluación orientada a métricas sensibles al desbalance de clases.

II. DATOS Y ANÁLISIS EXPLORATORIO DE DATOS

A. Descripción del dataset

Se utiliza el archivo `WA_Fn-UseC_-Telco-Customer-Churn.csv` de la publicación Telco Customer Churn de BlastChar en Kaggle [1]. El archivo contiene información de 7.043 clientes y 21 columnas, incluyendo variables demográficas, de servicio, de cuenta y de facturación. Cada fila corresponde a un cliente. Las columnas incluyen un identificador, la variable objetivo Churn y 19 características que podrían utilizarse para el modelado. De estas, tres son numéricas y 16 categóricas.

SeniorCitizen es categórica binaria aunque se almacene como entero. TotalCharges inicialmente se lee como texto y se convierte a número. La Tabla I resume las columnas y sus tipos de variables.

B. Calidad de datos y tratamiento de faltantes

No se encontraron filas duplicadas ni identificadores repetidos. La revisión tampoco detectó cargos o antigüedades negativos, antigüedades no enteras, valores ajenos a 0/1 en SeniorCitizen ni categorías distintas de Yes/No en Churn. Se comprobó además la correspondencia entre ausencia de internet y la categoría *No internet service* de los complementos, así como entre ausencia de telefonía y *No phone service*; no hubo inconsistencias en esas comprobaciones.

La inspección inicial no reconocía faltantes porque TotalCharges contenía espacios. Tras convertirla a número aparecieron 11 valores ausentes, equivalentes al 0.16 % de los clientes. Todos presentan tenure=0 y Churn=No. Esto podría corresponder a clientes recién incorporados al servicio, aunque no permite confirmar que el monto correcto sea cero.

Se mantienen los 7043 clientes y no se imputan cargos durante el EDA. Los resúmenes que requieren TotalCharges usan sus 7032 valores disponibles. Por tanto, no se elimina una fila de los demás análisis por ese único faltante.




Figura 1. Distribución del abandono en los 7043 clientes. Las etiquetas muestran cantidad y porcentaje de cada clase.

C. Revisión de valores atípicos

Se empleó la regla de 1.5 veces el rango intercuartílico, que corresponde a los límites habituales de un boxplot [3]. Para $IQR = Q_3 - Q_1$, se revisan los valores fuera del intervalo $[Q_1 - 1.5IQR, Q_3 + 1.5IQR]$.

En la base completa no se identificaron valores fuera de esos límites para las tres variables cuantitativas. Sin embargo, dentro del grupo que abandonó se señalaron 23 valores de antigüedad y 109 de cargo acumulado. Cada grupo tiene sus propios cuartiles, por ello, los resultados globales y por grupo no se contradicen. Los conteos no se suman como clientes distintos, ya que podrían superponerse. Se conservan los valores observados porque estar fuera de estos límites no demuestra que sean incorrectos. Del mismo modo, no encontrar valores atípicos no garantiza que todos los datos estén libres de errores.

D. Distribución de clases

Hay 5174 clientes con Churn=No (73.46 %) y 1869 con Churn=Yes (26.54 %), como muestra la Fig. 1. La clase positiva es minoritaria, pero ese hecho no determina por sí solo cuán difícil será clasificarla. Un modelo que siempre prediga No obtendría 73.46 % de exactitud, pero no detectaría ningún abandono. Por eso, la evaluación también debe considerar cuántos abandonos detecta el modelo y cuántas falsas alertas genera.

E. Distribuciones numéricas y comparación por abandono

La Tabla II presenta las estadísticas descriptivas. La antigüedad mediana es 29 meses y su mitad central se encuentra entre 9 y 55 meses. En el cargo acumulado, la media de 2283.30 supera a la mediana de 1397.48, en concordancia con una distribución extendida hacia montos altos. El cargo mensual presenta el orden contrario, con media de 64.76 y mediana de 70.35.

Entre quienes abandonaron, la antigüedad mediana es 10 meses, frente a 38 meses entre quienes no abandonaron. Su cargo mensual mediano es mayor (79.65 frente a 64.43),

Tabla I
VARIABLES DEL DATASET Y SUS TIPOS

Grupo	Variables	Tipo o descripción
Identificador	customerID	Texto, único por cliente
Objetivo	Churn	Categoría binaria (No/Yes)
Perfil	gender, SeniorCitizen, Partner, Dependents	Categorías binarias
Antigüedad	tenure	Número entero de meses
Telefonía	PhoneService, MultipleLines	Catógicas
Internet	InternetService	Catógica (DSL, Fiber optic o No)
Adicionales	OnlineSecurity, OnlineBackup, DeviceProtection, TechSupport, StreamingTV, StreamingMovies	Catógicas
Cuenta	Contract, PaperlessBilling, PaymentMethod	Catógicas
Cargos	MonthlyCharges, TotalCharges	Numéricas, cargo mensual y acumulado

Tabla II
RESUMEN DE VARIABLES CUANTITATIVAS

Medida	Antigüedad	Cargo mensual	Cargo acumulado
Observaciones	7043	7043	7032
Media	32.37	64.76	2283.30
Mediana	29.00	70.35	1397.48
Desv. estándar	24.56	30.09	2266.77
Q1	9.00	35.50	401.45
Q3	55.00	89.85	3794.74
Mínimo	0.00	18.25	18.80
Máximo	72.00	118.75	8684.80

pero su cargo acumulado mediano es menor (703.55 frente a 1683.60). Una persona puede pagar más por mes y acumular menos si lleva menos tiempo contratando el servicio. Las cajas de la Fig. 2 también se superponen, por lo que estas características no separan perfectamente a quienes abandonaron de quienes no lo hicieron.

Los histogramas muestran concentraciones de quienes abandonaron en antigüedades y cargos acumulados bajos. Muestran cantidades de clientes, así que las diferencias de altura también reflejan el distinto tamaño de los grupos. Por eso, no deben interpretarse como probabilidades de abandono por intervalo.

F. Correlaciones entre variables cuantitativas

Como se observa en la Fig. 3, la correlación de Pearson entre antigüedad y cargo acumulado es 0.826; entre cargo mensual y acumulado, 0.651; y entre antigüedad y cargo mensual, 0.248. El acumulado está asociado con el tiempo y los pagos, pero no necesariamente equivale a multiplicar los meses por el cargo mensual actual. Estas asociaciones no justifican eliminar automáticamente una variable ni constituyen por sí solas una fuga de información.

Para cada correlación se utilizan los clientes con datos disponibles en ambas variables. Las comparaciones que incluyen el cargo acumulado consideran 7032 clientes, mientras que la comparación entre antigüedad y cargo mensual utiliza los 7043.

G. Variables categóricas y abandono

Se calculó el porcentaje de abandono respecto al total de clientes de cada categoría. Esta comparación evita confundir

Tabla III
CLIENTES Y ABANDONO POR CATEGORÍAS SELECCIONADAS

Categoría	Clientes	Abandono (%)
<i>Contrato</i>		
Mensual	3875	42.71
Un año	1473	11.27
Dos años	1695	2.83
<i>Internet</i>		
DSL	2421	18.96
Fibra óptica	3096	41.89
Sin internet	1526	7.40
<i>Método de pago</i>		
Cheque electrónico	2365	45.29
Cheque por correo	1612	19.11
Transferencia automática	1544	16.71
Tarjeta de crédito automática	1522	15.24

una categoría numerosa con una de mayor proporción de abandono. La Tabla III reúne contrato, internet y método de pago.

Los contratos mensuales presentan 42.71 % de abandono, frente a 11.27 % y 2.83 % en contratos de uno y dos años. La diferencia entre los extremos es de 39.88 puntos porcentuales. Esta diferencia muestra una asociación con el abandono, aunque los grupos también pueden diferir en antigüedad y servicios. Por eso, cambiar el contrato no garantiza que un cliente permanezca más tiempo.

La fibra óptica presenta 41.89 %, frente a 18.96 % en DSL. Como no se midió la velocidad, las fallas ni la satisfacción, estos resultados no permiten concluir que la fibra sea de peor calidad. El cheque electrónico presenta 45.29 %, mientras que los otros métodos se sitúan entre 15.24 % y 19.11 %. El método de pago podría estar relacionado con el perfil o contrato de los clientes, pero los datos no permiten confirmar la razón de esta diferencia.

Entre clientes con internet, la ausencia de seguridad en línea se asocia con 41.8 % de abandono, frente a 14.6 % cuando se dispone de ella; para soporte técnico, los valores son 41.6 % y 15.2 %. La categoría *No internet service* representa una situación distinta de no contratar el complemento y reúne a los mismos 1526 clientes en varias columnas. No debe contarse




Figura 2. Antigüedad, cargo mensual y cargo acumulado según abandono. No y Yes indican ausencia y presencia de abandono registrado. Los puntos fuera de los bigotes se determinan dentro de cada grupo.




Figura 3. Matriz de correlación de Pearson entre antigüedad, cargo mensual y cargo acumulado.

como evidencia independiente en cada comparación.

No todos los complementos presentan diferencias similares. Respaldo en línea muestra 39.9 % sin el complemento y 21.5 % con él; protección del dispositivo, 39.1 % y 22.5 %. Las diferencias son menores en streaming de televisión (33.5 % y 30.1 %) y películas (33.7 % y 29.9 %). Estos porcentajes comparan las categorías No y Yes y excluyen a quienes no tienen internet.

En género, los porcentajes son cercanos (26.9 % en Female y 26.2 % en Male). En SeniorCitizen, la categoría 1 presenta 41.7 %, frente a 23.6 % en la categoría 0. También hay diferencias por pareja (33.0 % sin pareja y 19.7 % con pareja), dependientes (31.3 % y 15.5 %) y facturación sin papel (33.6 % con ella y 16.3 % sin ella). Estas diferencias describen los grupos de la muestra. Todavía falta evaluar cuánto aportan estas variables al modelo y si sus errores varían entre grupos.




Figura 4. Porcentaje de abandono dentro de cada combinación de contrato y antigüedad. Cada intervalo corresponde a un grupo distinto de clientes.

H. Comparaciones conjuntas

Se agrupa tenure en 0–12, 13–24, 25–48 y 49–72 meses para distinguir hasta un año, el segundo año, entre dos y cuatro años y más de cuatro años de permanencia. Estos intervalos se eligieron para facilitar la comparación y no fueron definidos por un modelo. La variable original se conserva sin modificar. Las proporciones se calculan dentro de cada combinación, aunque los intervalos tengan distinta amplitud.

La Fig. 4 muestra que los contratos mensuales presentan más abandono dentro de cada intervalo. En 0–12 meses, las tasas son 51.35 %, 10.48 % y 0 % para contratos mensuales, anuales y de dos años. Sin embargo, los tamaños respectivos son 1994, 124 y 68 clientes. En el grupo de 68 clientes no se observaron abandonos, pero eso no significa que su probabilidad real sea cero. En 49–72 meses las tasas son 26.02 %, 12.93 % y 3.33 %, con 342, 634 y 1263 clientes.

La diferencia entre contratos se mantiene dentro de estos grupos de antigüedad. Aun así, los intervalos son amplios y quedan otras características sin comparar. Tampoco puede interpretarse que permanecer más meses reduzca por sí mismo el riesgo de abandono.




Figura 5. Abandono según servicio de internet dentro de cada contrato. La categoría sin internet se distingue de DSL y fibra.

Al separar por contrato, la fibra también mantiene mayor abandono que DSL (Fig. 5). Las tasas son 54.61 % frente a 32.22 % en contratos mensuales, 19.29 % frente a 9.30 % en anuales y 7.23 % frente a 1.91 % en contratos de dos años. Las combinaciones de fibra y DSL cuentan, respectivamente, con 2128 y 1223 clientes mensuales, 539 y 570 anuales, y 429 y 628 de dos años. La diferencia no desaparece al separar por contrato, aunque todavía podrían intervenir cargos, antigüedad u otros atributos.

I. Posibles sesgos y fuga de información

La documentación presenta los datos como un ejemplo de una empresa ficticia [2]. No se conoce cómo se seleccionaron los clientes, por lo que no puede afirmarse que la muestra represente al mercado peruano. Además, algunos perfiles tienen menor presencia: `SeniorCitizen=1` reúne 1142 clientes, frente a 5901 en la otra categoría. Por estas diferencias de tamaño y de abandono, será útil revisar los errores del modelo por grupo. Sin embargo, estas diferencias por sí solas no demuestran discriminación.

También existe una limitación temporal. Los clientes de mayor antigüedad son quienes permanecieron el tiempo suficiente para alcanzar ese grupo. Compararlos con clientes recientes no permite saber qué pasaría con una misma persona si permaneciera más tiempo. Además, no se cuenta con las fechas en que se registró cada variable, por lo que falta comprobar si esa información estaba disponible antes del abandono.

La fuga de información ocurre cuando el entrenamiento utiliza información que no estaría disponible al predecir [4]. Se excluirán de las entradas `Churn` y su copia numérica `abandono`, pues ambas representan el objetivo. `customerID` también se excluirá, ya que identifica a cada cliente y no describe sus características. Las correlaciones entre cargos y antigüedad pueden indicar información redundante, pero no son por sí solas una fuga de información.

J. Síntesis del EDA y siguientes pasos

El EDA identifica diferencias por contrato, antigüedad, internet, método de pago y ciertos complementos. Las comparaciones conjuntas muestran que algunas diferencias permanecen al separar por contrato o antigüedad. No establecen causas ni determinan todavía qué variables aportarán más a un modelo.

Para P2 se propone definir el momento de predicción y separar los datos de entrenamiento y prueba manteniendo la proporción de clases. La imputación y la codificación se ajustarán únicamente con los datos de entrenamiento. Se conservará inicialmente la antigüedad original, omitiendo el grupo creado solo para visualizar. Se comparará un modelo que siempre prediga la clase mayoritaria con al menos dos modelos supervisados, por ejemplo regresión logística y un árbol de decisión. Sus parámetros se elegirán con los datos de validación, sin utilizar los de prueba. Se reportarán matriz de confusión, precisión y recall, junto con una métrica para evaluar qué tan bien el modelo asigna mayor riesgo a quienes abandonan.

REFERENCIAS

- [1] BlastChar, "Telco Customer Churn," Kaggle, conjunto de datos de ejemplo de IBM, consultado: 21 sep. 2026. [Online]. Available: <https://www.kaggle.com/datasets/blastchar/telco-customer-churn>
- [2] IBM Samples Team, "New base samples for IBM Cognos Analytics 11.1.1," IBM Community, Nov. 2018, publicado: 26 nov. 2018. Consultado: 21 sep. 2026. [Online]. Available: <https://community.ibm.com/community/user/blogs/steven-macko/2018/11/26/new-base-samples-for-ibm-cognos-analytics-1111>
- [3] NIST/SEMATECH, "1.3.3.7. Box Plot," e-Handbook of Statistical Methods, consultado: 21 sep. 2026. [Online]. Available: <https://www.itl.nist.gov/div898/handbook/eda/section3/boxplot.htm>
- [4] Scikit-learn developers, "Common pitfalls and recommended practices," Documentación de scikit-learn, sección 12.2, Data leakage. Consultado: 21 sep. 2026. [Online]. Available: https://scikit-learn.org/stable/common_pitfalls.html